Enunciado do Trabalho Prático

1 Destinatários e Objetivos

Este trabalho destina-se a todos os estudantes inscritos na unidade curricular de Tópicos Avançados de Armazenamento de Dados que pretendam obter aprovação à Unidade Curricular.
Com a realização do trabalho prático, pretende-se que os alunos ponham em prática todos os conhecimentos adquiridos nos diversos modelos de armazenamento de dados existentes, não só na implementação de sistemas operacionais, mas também de sistemas de suporte à decisão.

2 Caso de estudo

Para a realização do trabalho prático, os alunos devem propor um caso de estudo suportado por um conjunto de requisitos de análise para a implementação de um sistema de Data Warehousing. Para suportar o tema proposto, os grupos devem justificar a escolha do caso de estudo com um conjunto de dados que permitam suportar os requisitos identificados.
Com base nos requisitos identificados, cada grupo deverá implementar um sistema que represente e suporte diversos cenários relacionados com a análise de negócio.

Privilegia-se a utilização de datasets que reflitam atividade operacional, isto é, registos ao nível do evento individual que são gerados de forma contínua ao longo do tempo (ex.: ocorrências registadas pela proteção civil, alertas e despachos de meios, deteções de focos de incêndio por satélite, leituras de estações meteorológicas ou de sensores), em detrimento de *snapshots* ou de datasets já agregados (ex.: totais anuais de área ardida por concelho, frequentemente disponibilizados em portais de dados abertos). Só com dados desta natureza é possível definir de forma rigorosa o grão das tabelas de factos e demonstrar um verdadeiro processo de povoamento incremental.

Datasets agregados ou estáticos poderão ser utilizados apenas como fontes complementares (ex.: enriquecimento de dimensões geográficas ou demográficas), devendo essa opção ser justificada. Caso a fonte operacional escolhida não seja atualizada com frequência suficiente, admite-se a simulação da geração contínua de eventos a partir dos dados históricos (ex.: *replay* ordenado por data/hora), desde que o mecanismo seja descrito.
O sistema deverá ser capaz de:

- Recolher e integrar dados provenientes de diferentes fontes (ex.: relatórios oficiais, bases de dados governamentais, dados meteorológicos, sensores, dados geográficos, entre outros);
- Estruturar a informação num Data Warehouse com pelo menos duas tabelas de factos (sujeito a validação do docente) e 2 dimensões (para além das dimensões temporais). Deve existir pelo menos uma dimensão de variação com história.
- Facultar uma análise multidimensional, permitindo comparações por localização, tempo, intensidade, tipologia do incêndio, causas, recursos utilizados, entre outros;
- Disponibilizar uma camada de proveniência dos dados com base no modelo W3C PROV (PROV-O);
- Explorar, se necessário, outras tecnologias de armazenamento (Data Lake, bases de dados de grafos, vetoriais, etc.) para complementar o sistema de suporte à decisão.

2.1 Componentes do trabalho

O sistema a desenvolver deverá estar caracterizado em seis componentes:

- **Caracterização das Fontes de Dados**: identificação e descrição dos datasets escolhidos, bem como da estratégia de extração e integração. Para cada fonte deverá ser indicado o grão (evento a que corresponde cada registo), a frequência de atualização e o mecanismo que permite identificar novos registos ou alterações (ex.: *timestamps*, identificadores incrementais). Sempre que possível, a extração deverá ser automatizada (via APIs, scraping, downloads programáticos, etc.).
- **Componente de Integração de Dados**: preparação dos dados (auditoria, limpeza, transformação, enriquecimento, etc.), alinhada com os requisitos identificados para os data marts. O processo deverá seguir a arquitetura *medallion* e as regras definidas na secção "Regras para o processo de povoamento (ETL)".
- **Implementação do(s) Data Mart(s)**: criação de uma arquitetura de Data Warehouse que suporte a análise multidimensional. Devem ser apresentadas pelo menos duas tabelas de factos devidamente justificadas, bem como as respetivas dimensões.
- **Camada de Proveniência**: registo da proveniência dos dados tendo por base o modelo W3C PROV. Deverão ser apresentadas pelo menos três consultas que respondam a questões como: "de que fonte(s) e de que execução de carregamento provêm os factos de um dado mês e distrito?", "que tabelas do Data Warehouse são afetadas se uma fonte for alterada?" ou "quando foi atualizada pela última vez cada tabela de factos?".

- **Componente de Visualização de Dados**: desenvolvimento de dashboards e relatórios que apresentem os resultados da análise.

2.2 Regras para o processo de povoamento (ETL)

A tecnologia utilizada no processo de povoamento fica ao critério de cada grupo. Independentemente da tecnologia, o processo de ETL deverá respeitar as regras seguintes, que serão tidas em conta na avaliação. Não serão valorizadas soluções compostas por *scripts* monolíticos em que extração, limpeza, transformação e carregamento surgem misturados no mesmo código.

- **Modelo Conceptual com BPMN**: Devem ser elaborados modelos conceptuais em BPMN (de acordo com o discutido e apresentado nas aulas) para representar os principais processos e os seus componentes. Devem identificar os procedimentos típicos de ETL utilizados.
- **Componentes coesos**: cada componente deverá ter uma única responsabilidade e atuar numa única transição entre camadas. Por exemplo: um extrator por fonte (fonte → Bronze), uma transformação por entidade (Bronze → Silver) e um carregador por dimensão ou tabela de factos (Silver → Gold). Um mesmo componente não deverá extrair, limpar e carregar.
- **Baixo acoplamento**: os componentes comunicam apenas através das tabelas ou ficheiros das camadas, cuja estrutura funciona como contrato e deverá estar documentada. Nenhum componente deverá invocar diretamente outro nem depender da sua lógica interna. Deverá ser possível, por exemplo, substituir o extrator de uma fonte sem alterar o resto do processo.
- **Orquestração separada**: a ordem de execução e as dependências entre componentes são definidas num único ponto (ex.: pacote mestre no SSIS, DAG no Airflow, *script* ou *Makefile* de orquestração), que não contém lógica de transformação.
- **Configuração separada do código**: ligações, caminhos, credenciais e parâmetros (ex.: datas de referência) deverão estar em ficheiros de configuração, parâmetros de projeto ou variáveis de ambiente, e nunca escritos diretamente no código.
- **Povoamento inicial e incremental com os mesmos componentes**: a diferença entre ambos deverá resultar apenas de parâmetros e de uma marca de água por fonte, guardada numa tabela de controlo. Todos os componentes deverão ser idempotentes: voltar a executar a mesma carga não pode gerar duplicados.

- **Controlo das execuções**: cada execução de cada componente deverá ser registada numa tabela de controlo (início, fim, estado e número de registos lidos, inseridos e rejeitados).

2.3 Relatório

Deverá ainda ser elaborado um relatório em formato de artigo, abordando todos os passos do desenvolvimento do sistema de acordo com a metodologias e métodos apresentados ao longo das aulas. O artigo deverá ser elaborado utilizando o *template* LNCS[1] e deverá, no mínimo, conter os seguintes conteúdos (podem ser reorganizados em termos de estrutura):

- **Introdução**: enquadramento do tema dos incêndios e a relevância da sua análise com sistemas de Business Intelligence e tecnologias complementares.
- **O Sistema de Business Intelligence**:
    - Caso de aplicação: descrição do caso de estudo e fundamentação da relevância do sistema.
    - Arquitetura do sistema: requisitos, análise das fontes (incluindo a justificação da sua natureza operacional e do grão escolhido), estrutura do Data Warehouse (modelação concetual, lógica e física), bem como tecnologias utilizadas.
    - Processo de povoamento: caracterização das camadas Bronze, Silver (área de retenção) e Gold, dos componentes de ETL e dos contratos entre camadas. A modelação concetual dos processos de povoamento deverá ser apresentada em BPMN (processo inicial e incremental), evidenciando o ponto em que é registada a proveniência.
    - Análise e Visualização de Dados: exemplos de dashboards e relatórios construídos.
- Conclusões e Trabalho Futuro: análise crítica do trabalho.

Como referência, o artigo deverá ter até 25 páginas.

3 Datas e considerações

Os alunos devem formar grupos de trabalho de no máximo **3** elementos. O trabalho deve ser entregue até ao dia 14 de Dezembro, devendo a entrega ser feita através da página da unidade curricular em http://moodle.estg.ipp.pt.

[1] https://www.springer.com/gp/computer-science/lncs/conference-proceedings-guidelines

4 Entrega e apresentação

Todos os elementos do grupo deverão submeter o trabalho no *link* respetivo, devendo entregar em formato zip e separado por pastas:

- As fontes utilizadas no trabalho prático;
- Processo de povoamento, organizado por camadas e componentes, e estruturas de suporte;
- Backup e script de desenvolvimento do sistema;
- Ficheiros necessários para reproduzir as *dashboards*/relatórios produzidos;
- Relatório abordando todos os tópicos apresentados no modelo de relatório disponível na plataforma moodle.
- Um documento com os passos para a reprodução de uma demonstração do trabalho tendo em consideração a inexistência de dados no *Data Warehouse*, o seu povoamento inicial, exemplo de povoamento incremental, consulta da proveniência gerada por ambos e visualização de dados.

Será ainda realizada uma apresentação de no máximo 15 minutos, apresentando o caso de estudo, pressupostos associados, arquitetura da solução desenvolvida e ainda uma breve demonstração do trabalho desenvolvido. A data para a apresentação será posteriormente comunicada.